Resolución de examen Introducción a IA 2020

In [1]:

```
import numpy as np
import matplotlib.pyplot as plt

from numpy.random import MT19937
from numpy.random import RandomState, SeedSequence
rs = RandomState(MT19937(SeedSequence(123456789)))
```

Ejercicio 2

Pre-procesamiento del dataset

a) Obtener el dataset desde el siguiente link. La primera columna representa los datos de entrada y la segunda columna representa los datos de salida.

```
In [2]:
```

```
DATASET_FILENAME = "data/clase_8_dataset.csv"
```

b) Levantar el dataset en un arreglo de Numpy.

In [31:

```
class Data(object):
   def split(self, percentage=0.8):
        return NotImplemented
class DataXY(Data):
   def __init__(self, path, skip_header=True,delimiter=','):
        self.dataset = self._build_dataset(path,skip_header,delimiter)
   def get(self):
        return self.dataset
   def split(self, percentage=0.8):
        """ Particiona un dataset y devuelve las dos partes
        dataset sz = self.dataset.shape[0]
        i0 = int(dataset sz*percentage)
        indices = np.random.permutation(dataset sz)
        training idx, validation idx = indices[0:i0], indices[i0:]
        return self.dataset[training_idx], self.dataset[validation_idx]
   def build dataset(self,path,skip header,delimiter):
        return np.genfromtxt(path, skip_header=skip_header, delimiter=delimiter)
```

In [4]:

```
dataset = DataXY(DATASET_FILENAME)
data = dataset.get()
data.shape
```

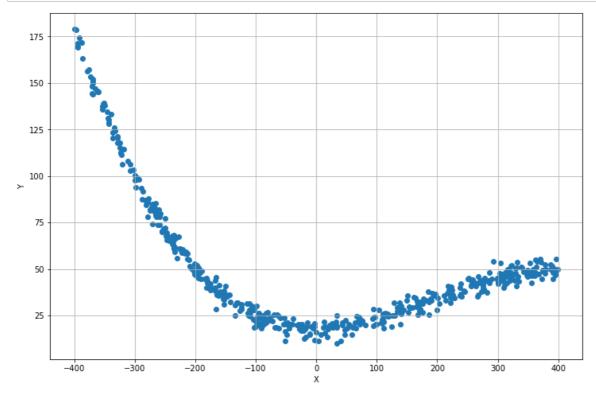
Out[4]:

(499, 2)

c) Graficar el dataset de manera tal que sea posible visualizar la nube de puntos.

In [5]:

```
plt.figure(figsize=(12,8))
plt.scatter(data[:,0],data[:,1])
plt.xlabel("X")
plt.ylabel("Y")
plt.grid(which="Both")
```



d) Partir el dataset en train (80%) y test (20%).

In [6]:

```
ds_train, ds_test = dataset.split()
ds_train.shape, ds_test.shape
```

Out[6]:

```
((399, 2), (100, 2))
```

Ejercicio 3

Utilizar regresión polinómica para hacer "fit" sobre la nube de puntos del train. Para este ejercicio, se desea utilizar la fórmula cerrada de la optimización polinómica. El modelo es de la forma $y = [W_n \dots W_0][X^n X^{n-1} \dots 1].$

In [7]:

```
class BaseModel(object):
    def init (self):
        self.model = None
    def fit(self, X, Y):
        return NotImplemented
    def predict(self, X):
        return NotImplemented
class LinearRegression(BaseModel):
    def fit(self, X, y):
        if len(X.shape) == 1:
            W = X.T.dot(y) / X.T.dot(X)
            W = np.linalg.inv(X.T.dot(X)).dot(X.T).dot(y)
        self.model = W
    def get model(self):
        return self.model
    def predict(self, X):
        return self.model * X
    def predict_n_coeff(self,X,coeff):
        y_hat = 0
        for c in range(coeff):
            y hat += w[c]*X**(coeff-c)
        return y_hat
```

In [8]:

```
class Metric(object):
    def __call__(self, target, prediction):
        return NotImplemented

class MSE(Metric):
    def __init__(self):
        Metric.__init__(self)

def __call__(self, target, prediction):
    n = target.size
    return np.sum((target - prediction) ** 2) / n
```

a) Para n = 1 (modelo lineal con ordenada al origen), hacer un fit del modelo utilizando K-FOLDS. Para K-FOLDS partir el train dataset en 5 partes iguales, utilizar 4/5 para entrenar y 1/5 para validar. Informar el mejor modelo obtenido y el criterio utilizado para elegir dicho modelo (dejar comentarios en el código).

In [9]:

```
def k folds(X train, y train, k=5):
    error = MSE()
    chunk_size = int(len(X train) / k)
    mse list = []
    models list = []
    for i in range(0, len(X train), chunk size):
        end = i + chunk size if i + chunk size <= len(X train) else len(X train)</pre>
        new X valid = X train[i: end]
        new y valid = y train[i: end]
        new X train = np.concatenate([X train[: i], X train[end:]])
        new y train = np.concatenate([y train[: i], y train[end:]])
        regression = LinearRegression()
        regression.fit(new X train, new y train )
        w = regression.get model()
        if X train.ndim > 1:
            prediction = 0
            coeff = X train.shape[1]
            for c in range(coeff):
                prediction += w[c]*new X valid**(coeff-c)
        else:
            prediction = regression.predict(new X valid)
        mse list.append(error(new y valid, prediction))
        models list.append(w)
    return mse list, models list
```

In [10]:

```
X_train = ds_train[:,0]
y_train = ds_train[:,1]
X_test = ds_test[:,0]
y_test = ds_test[:,1]
```

In [11]:

```
mse_list, model_list = k_folds(X_train,y_train)
mse_list
```

Out[11]:

```
[2961.406492893372,
3163.9625016329005,
3111.049347622796,
3341.193602850409,
3356.826818658892,
5604.455329147998]
```

```
In [12]:
```

```
def get_best_model(mse_list, model_list):
    best_model_idx = np.argmin(mse_list)
    best_mse = np.min(mse_list)
    return best_model_idx, best_mse
```

In [13]:

```
best_model_idx, best_mse = get_best_model(mse_list, model_list)
best_model_idx, best_mse
```

Out[13]:

```
(0, 2961.406492893372)
```

R: Se elije el modelo que minimiza el error cuadrático medio en el 1/5 separado del train set para validar.

In [14]:

```
w = model_list[best_model_idx]
w
```

Out[14]:

-0.0906927372146787

Nota: Se guarda el modelo para ser usado en un ejercicio posterior.

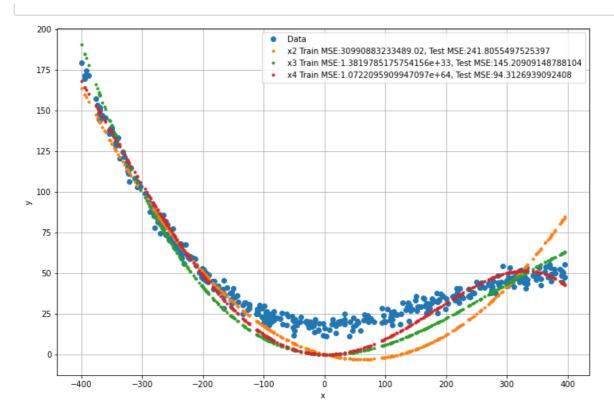
In [15]:

```
model_3a = w # usado más adelante
```

b) Repetir el punto (a), para $n = \{2,3,4\}$. Computar el error de validación y test del mejor modelo para cada n.

In [16]:

```
model results = []
x = X_{train}
y = y train
coeffs = [2,3,4]
x coeffs = []
y hat coeffs = []
for coeff in coeffs:
    x acc = []
    for c in range(coeff):
        x acc.append(x**(coeff-c))
    xx = np.vstack(x acc).T
    mse_list, model_list = k_folds(xx, y.reshape(-1, 1))
    best model idx, best mse = get best model(mse list, model list)
    w = model list[best_model_idx]
    # Train MSE
    train mse = best mse
    # Test MSE
    error = MSE()
    y hat test = 0
    for c in range(coeff):
        y hat test += w[c]*X test**(coeff-c)
    test_mse = error(y_test, y_hat_test)
    # Sólo para el plot
    y hat = 0
    for c in range(coeff):
        y hat += w[c]*X train**(coeff-c)
    #y hat coeffs.append(y hat)
    new model = {
        "model": w,
        "coeff": coeff,
        "x": x,
        "y": y_hat,
        "legend": f"x{coeff} Train MSE:{train_mse}, Test MSE:{test_mse}",
        "train mse": train mse,
        "test_mse": test_mse
    model_results.append(new_model)
def plot_model_results(x,y,model_results):
    plt.figure(figsize=(12,8))
    plt.plot(x,y,'o')
    legend= ["Data"]
    for m in model_results:
        plt.plot(m["x"],m["y"],'.')
        legend.append(m["legend"])
    plt.grid(which="Both")
    plt.xlabel("x")
    plt.ylabel("y")
    plt.legend(legend)
    plt.show()
plot model results(x,y,model results)
```



c) Elegir el polinomio que hace mejor fit sobre la nube de puntos y explicar el criterio seleccionado (dejar comentarios en el código).

In [17]:

```
for m in model_results:
    print(m["legend"])
```

x2 Train MSE:30990883233489.02, Test MSE:241.8055497525397 x3 Train MSE:1.3819785175754156e+33, Test MSE:145.20909148788104

x4 Train MSE:1.0722095909947097e+64, Test MSE:94.3126939092408

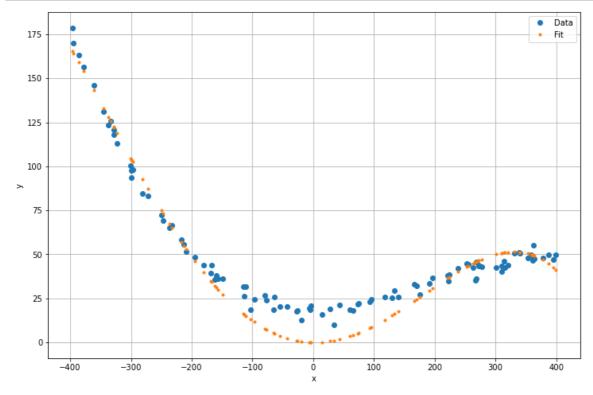
R: El mejor polinomio es el x4 dado que tiene menor error cuadrático medio en el test set.

d) Graficar el polinomio obtenido y el dataset de test.

In [18]:

```
coeff = 4
y_hat_best_test = 0
for c in range(coeff):
    y_hat_best_test += w[c]*X_test**(coeff-c)

plt.figure(figsize=(12,8))
plt.plot(X_test,y_test,'o')
plt.plot(X_test,y_hat_best_test,'.')
plt.grid(which="Both")
plt.xlabel("x")
plt.ylabel("y")
plt.legend(["Data","Fit"])
plt.show()
```



Ejercicio 4

Para el mejor modelo seleccionado en (3c) (el mejor "n"), hacer la optimización utilizando Mini-Batch Gradient Descent (partir el train dataset en 4/5 para entrenar y 1/5 para validar).

- Para la parte de mini-batch no hace falta que use k-fold
- Hagan como se suele hacer en los problema de deep learning
- Tomen el dataset de training
- Cuando arranca la epoch, separen el dataset de training en 4/5 para entrenamiento y 1/5 para validación
- Hagan la epoch con 4/5 de los datos (vayan acumulando el error de entrenamiento asi pueden calcularle el promedio al terminar la epoch)
- Cuando termina la epoch (pasaron por los 4/5 de los datos de entrenamiento), calculen el error que produce el modelo sobre los datos de validación.
- Al finalizar la epoch, tienen un error para el entrenamiento y un error para la validacion.
- Hagan esto para todas las epochs.
- Cuando termina el entrenamiento, pueden graficar el error de entrenamiento y el error de validacion en funcion del numero de epoch :sonriente:

In [19]:

```
coeff = 4
x_acc = []
for c in range(coeff):
    x_acc.append(X_train**(coeff-c))
xx = np.vstack(x_acc).T
```

In [20]:

```
def mini_batch_gradient_descent(X_train, y_train, lr=0.0001, amt_epochs=100,batc
h size=16):
    shapes:
        X t = nxm
        y t = nx1
        W = mx1
    b = batch_size
    m = X train.shape[1]
    mse = MSE()
    # initialize random weights.
    W = np.random.randn(m).reshape(m, 1)
    train history = []
    test_history = []
    for i in range(amt epochs):
        ### 4/5 Train set Splitting
        dataset sz = X train.shape[0]
        i0 = int(dataset sz*0.8)
        indices = np.random.permutation(dataset sz)
        training idx, validation idx = indices[0:i0], indices[i0:]
        X new train = X train[training idx]
        y new train = y train[training idx]
        X new val = X train[validation idx]
        y new val = y train[validation idx]
        ###
        n = X new train.shape[0]
        idx = np.random.permutation(X new train.shape[0])
        X new train = X new train[idx]
        y new train = y new train[idx]
        train error sum = 0
        batch size = int(len(X new train) / b)
        for i in range(0, len(X new train), batch size):
            end = i + batch_size if i + batch_size <= len(X_new_train) else len(</pre>
X new train)
            batch_X = X_new_train[i: end]
            batch_y = y_new_train[i: end]
            prediction = np.matmul(batch X, W) # nx1
            error = batch y - prediction \# nx1
            grad_sum = np.sum(error * batch_X, axis=0)
            grad_mul = -2/batch_X.shape[0] * grad_sum # 1xm
            gradient = np.transpose(grad mul).reshape(-1, 1) # mx1
            W = W - (lr * gradient)
            train error sum = train error sum + mse(prediction,batch y)
        # Train error
        train error = np.average(train error sum)
```

```
# Val error
prediction = np.matmul(X_new_val, W) # nx1
test_error = mse(prediction, y_new_val)

train_history.append(train_error)
test_history.append(test_error)

return W, np.array(train_history),np.array(test_history)
```

a) Para cada epoch, calcular el error de train y el error de validation.

In [21]:

```
N_EPOCHS = 300
model, train_history,test_history = mini_batch_gradient_descent(
    xx,y_train.reshape(-1,1), lr=le-6, amt_epochs=N_EPOCHS)
```

```
/home/nhorro/anaconda3/lib/python3.7/site-packages/ipykernel_launche
r.py:12: RuntimeWarning: overflow encountered in square
   if sys.path[0] == '':
/home/nhorro/anaconda3/lib/python3.7/site-packages/ipykernel_launche
r.py:48: RuntimeWarning: overflow encountered in multiply
/home/nhorro/anaconda3/lib/python3.7/site-packages/numpy/core/fromnu
meric.py:90: RuntimeWarning: overflow encountered in reduce
   return ufunc.reduce(obj, axis, dtype, out, **passkwargs)
/home/nhorro/anaconda3/lib/python3.7/site-packages/numpy/core/fromnu
meric.py:90: RuntimeWarning: invalid value encountered in reduce
   return ufunc.reduce(obj, axis, dtype, out, **passkwargs)
/home/nhorro/anaconda3/lib/python3.7/site-packages/ipykernel_launche
r.py:45: RuntimeWarning: invalid value encountered in matmul
```

Nota: Es un problema bastante comun en regresion lineal polinomica, porque el error puede ser muy grande muy rapidamente Hagan la mejor regresion para n=1 Asi no luchan tanto con la convergencia, que basicamente es luchar mucho con los parametros

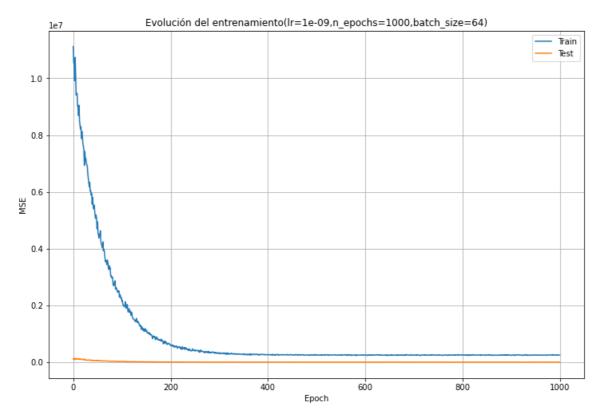
In [22]:

b) Graficar el error de train y el error de validación en función del número de epoch.

In [23]:

Out[23]:

<matplotlib.legend.Legend at 0x7f1e5d90f650>



c) Comparar los resultados obtenidos para el modelo entrenado con Mini-Batch, contra el modelo obtenido en (3c).

```
In [24]:
```

```
model = model[0][0]
```

In [25]:

```
model,model_3a
```

Out[25]:

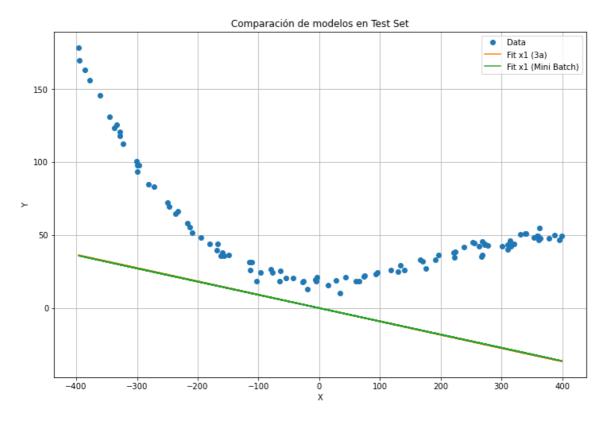
(-0.0915564139988859, -0.0906927372146787)

In [26]:

```
plt.figure(figsize=(12,8))
plt.grid(which="Both")
plt.title("Comparación de modelos en Test Set")
plt.plot(X_test, y_test,'o')
plt.plot(X_test, model*X_test)
plt.plot(X_test, model_3a*X_test)
plt.xlabel("X")
plt.ylabel("Y")
plt.legend(["Data", "Fit x1 (3a)", "Fit x1 (Mini Batch)"])
```

Out[26]:

<matplotlib.legend.Legend at 0x7f1e59a94fd0>



In [27]:

```
mse = MSE()
metrics = [mse(y_test, model_3a*X_test), mse(y_test, model*X_test)]
print("1) MSE x1(3A) en Test Set", metrics[0])
print("2) MSE x1(Mini Batch) en Test Set", metrics[1])
```

- 1) MSE x1(3A) en Test Set 3796.1425087146836
- 2) MSE x1(Mini Batch) en Test Set 3798.806266444816

In [28]:

```
print("El mejor modelo es:", np.argmin(metrics)+1)
```

El mejor modelo es: 1

Nota: se guarda para usar más adelante en el ejercicio 5.

In [29]:

```
best_mse_ex4 = np.min(metrics)
best_mse_ex4
```

Out[29]:

3796.1425087146836

Ejercicio 5

[EXTRA] Para el mejor modelo seleccionado en (3c), hacer la optimización utilizando Mini-Batch y regularización Ridge.

a) Computar el gradiente de J y codificar en Numpy la implementación del gradiente.

Nota: Se utiliza la misma implementación anterior agregando el parámetro opcional *ridge_param*.

In [30]:

```
def mini_batch_gradient_descent_ridge(X_train, y_train, lr=0.0001, amt_epochs=10
0,batch_size=16,ridge_param=None):
    shapes:
        X_t = nxm
        y t = nx1
        W = m \times 1
        ridge = Enable ridge regression
    b = batch size
    m = X train.shape[1]
    mse = MSE()
    # initialize random weights.
    W = np.random.randn(m).reshape(m, 1)
    train history = []
    test history = []
    for i in range(amt epochs):
        ### 4/5 Train set Splitting
        dataset_sz = X_train.shape[0]
        i0 = int(dataset sz*0.8)
        indices = np.random.permutation(dataset sz)
        training idx, validation idx = indices[0:i0], indices[i0:]
        X new train = X train[training idx]
        y new train = y train[training idx]
        X new val = X train[validation idx]
        y_new_val = y_train[validation_idx]
        n = X \text{ new train.shape}[0]
        idx = np.random.permutation(X new train.shape[0])
        X new train = X new train[idx]
        y_new_train = y_new_train[idx]
        train_error_sum = 0
        batch size = int(len(X new train) / b)
        for i in range(0, len(X_new_train), batch_size):
            end = i + batch size if i + batch size <= len(X new train) else len(
X_new_train)
            batch_X = X_new_train[i: end]
            batch y = y new train[i: end]
            prediction = np.matmul(batch_X, W) # nx1
            error = batch_y - prediction # nx1
            # Gradient (sin ridge regularization)
            grad sum = np.sum(error * batch X, axis=0)
            grad_mul = -2/batch_X.shape[0] * grad_sum # 1xm
            gradient = np.transpose(grad mul).reshape(-1, 1) # mx1
            # Gradient (c/ ridge regularization)
            if ridge_param is not None:
                gradient = gradient + (2.0 * ridge param)
```

```
W = W - (lr * gradient)
    train_error_sum = train_error_sum + mse(prediction,batch_y)

# Train error
    train_error = np.average(train_error_sum)

# Val error
    prediction = np.matmul(X_new_val, W) # nx1
    test_error = mse(prediction, y_new_val)

    train_history.append(train_error)
    test_history.append(test_error)

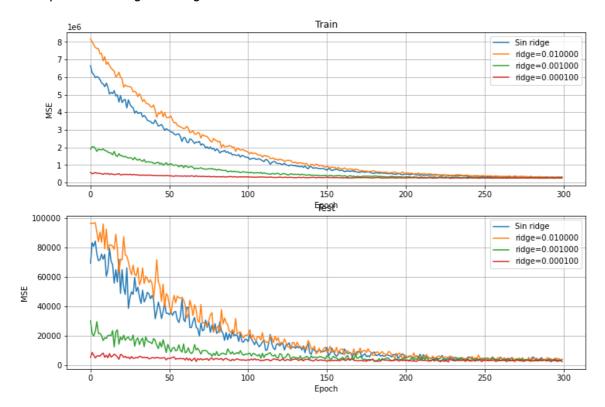
return W, np.array(train_history),np.array(test_history)
```

In [31]:

```
ridge params to test = [None, 0.01, 0.001, 0.0001]
ridge models = []
N EPOCHS = 300
fig, axs = plt.subplots(2,1,figsize=(12,8))
plt.title( f"Evolución del entrenamiento(lr={LEARNING_RATE}, n_epochs={N_EPOCHS},
batch size={BATCH SIZE})")
axs[0].set title("Train")
axs[1].set_title("Test")
axs[0].set xlabel("Epoch")
axs[0].set ylabel("MSE")
axs[0].grid(which="Both")
axs[1].set xlabel("Epoch")
axs[1].set ylabel("MSE")
axs[1].grid(which="Both")
legend = []
for ridge param in ridge params to test:
    model ridge, train history, test history = mini batch gradient descent ridge(
        X train.reshape(-1,1),y train.reshape(-1,1), lr=1e-9, amt epochs=N EPOCH
S, batch size=64, ridge param=ridge param)
    ridge models.append({
        "model": model ridge[0][0],
        "ridge param": ridge param,
        "best mse train": np.min(train history),
        "best mse test": np.min(test history)
    })
    epochs = np.arange(0, N EPOCHS)
    axs[0].plot(epochs,train history)
    axs[1].plot(epochs, test history)
    if ridge param is not None:
        legend.append("ridge=%f" %ridge_param )
    else:
        legend.append("Sin ridge")
axs[0].legend( legend )
axs[1].legend( legend )
```

Out[31]:

<matplotlib.legend.Legend at 0x7f1e599e4f50>



b) Comparar con el modelo obtenido en (4).

In [32]:

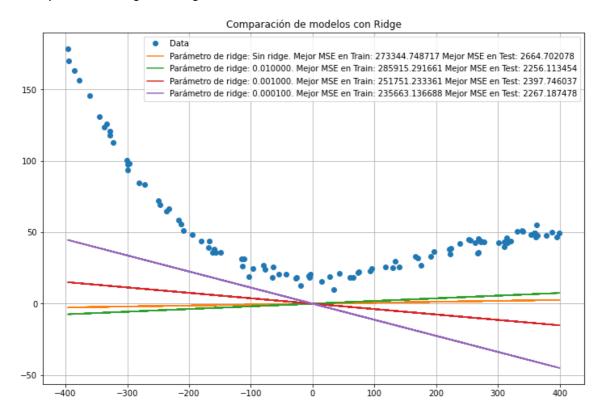
```
plt.figure(figsize=(12,8))
plt.grid(which="Both")
plt.title("Comparación de modelos con Ridge")
legends = ["Data"]
plt.plot(X_test, y_test,'o')
for m in ridge_models:
    if m["ridge_param"] is None:
        ridge_param = "Sin ridge"
    else:
        ridge_param = "%f" % m["ridge_param"]

legend = "Parámetro de ridge: %s. Mejor MSE en Train: %f Mejor MSE en Test:
%f" % ( ridge_param, m["best_mse_train"], m["best_mse_test"] )

plt.plot(X_test, m["model"]*X_test)
legends.append(legend)
plt.legend(legends)
```

Out[32]:

<matplotlib.legend.Legend at 0x7f1e59939750>



In [33]:

```
for m in ridge_models:
    if m["ridge_param"] is None:
        ridge_param = "Sin ridge"
    else:
        ridge_param = "%f" % m["ridge_param"]

    print("Parámetro de ridge: %s. Mejor MSE en Train: %f Mejor MSE en Test: %f"
        ( ridge_param, m["best_mse_train"], m["best_mse_test"] ))
print("Ejercicio 4 - Mejor MSE: %f" % best_mse_ex4)
```

```
Parámetro de ridge: Sin ridge. Mejor MSE en Train: 273344.748717 Mejor MSE en Test: 2664.702078

Parámetro de ridge: 0.010000. Mejor MSE en Train: 285915.291661 Mejor MSE en Test: 2256.113454

Parámetro de ridge: 0.001000. Mejor MSE en Train: 251751.233361 Mejor MSE en Test: 2397.746037

Parámetro de ridge: 0.000100. Mejor MSE en Train: 235663.136688 Mejor MSE en Test: 2267.187478

Ejercicio 4 - Mejor MSE: 3796.142509
```

Conclusiones:

- Para este modelo el uso de un término regularizador "ridge" puede reducir la cantidad de épocas necesarias para optimizar el modelo.
- Si bien hay diferencias en los MSEs de cada modelo evaluado, son bajas y por lo tanto pueden caer dentro del error numérico como para poder afirmar fehacientemente que un modelo es mejor que otro. Debería repetirse esta prueba con un modelo que haga un mejor fit (ej: el polinomio de grado 4).